Eötvös Loránd Tudományegyetem

Informatikai Kar

Algoritmusok és Alkalmazásaik Tanszék

Cache-optimális algoritmusok elemzése

Szabó László Ferenc
Docens

Nagy Péter
Programtervező Informatikus MSc

Budapest, 2023

Tartalomjegyzék

1. Bevezetés **3**

2. Cache modellje **4**

2.1. Csere stratégiák 5

2.1.1. Online algoritmusok 6

2.1.2. Verem stratégiák 6

2.1.3. OPT 7

2.1.4. LRU 8

2.1.5. FIFO 8

2.2. Asszociativitás 9

2.3. Írási stratégia 10

3. Gyorsítótár független algoritmusok **12**

3.1. Lista 12

3.1.1. Másolás 12

3.1.2. Partíció 13

3.1.3. Leszámláló rendezés 14

3.2. Mátrix szorzás 15

3.2.1. Gyorsítótár tudatos 16

3.2.2. Kettő-hatvány négyzetes mátrixok 17

3.2.3. Gyorsítótár független 18

3.2.4. Strassen algoritmus 19

3.2.5. Z-sorrend 20

3.3. Rendezés 21

3.4. FFT 21

3.5. Diff.egyenlet közelítés 21

3.6. Statikus keresőfa 21

3.7. Edénysor szita 21

3.7.1. A rekurzív fa 22

3.7.2. Rekurzív szita 23

3.7.3. Műveletigény gyorsítótár nélkül 25
3.7.4. A műveletigény alsó korlátja 28
3.7.5. Gyorsítótár független edény szita 30
3.7.6. Műveletigény gyorsítótárral 32
3.7.7. Cache-aware edényszita 34
3.7.8. Feltételek a gyorsítótár méretére 34
3.7.9. Tetszőleges n-ig, nem csak teljes fára 34
3.7.10. Az igazi program fix méretű számokkal 34
3.7.11. Az igazi program változó méretű számokkal 34

4. Szimulátor **35**
4.1. Igazi cache 35
4.2. Megoldás 35
4.3. Választható cache-ek 35
4.4. Tesztek 35

5. Mérési eredmények **36**

6. Irodalomjegyzék **37**

1. fejezet

Bevezetés

A modern számítógépek olyan sebességeket érnek el, hogy a jelterjedés fizikai korlátai már egy integrált áramkörön belül sem feltétlenül engedik meg az összes áramköri elem szinkron működést. A végrehajtó egység és a memória sebessége között már nagyságrendi különbségek vannak.

A probléma kezelésére gyorsítótárakat vezettek be a végrehajtó egység és a memória közé, ami az utoljára használt memóriaelemeket tárolja. A gyorsítótár sebessége nagyobb mint a memóriáé, de lassabb, mint a végrehajtó egységé. Egy modern számítógépben a gyorsítótáraknak hierarchiája is van, ahol egy gyorsítótár egy szintben alatta lévő másik gyorsítótár elemeit tárolja.

A gyorsítótárakkal ellátott számítógép legjobb kihasználásához olyan algoritmusokat kell tervezni, amik figyelembe veszik a gyorsítótárak hierarchiáját.

2. fejezet

Cache modellje

Az ideális gyorsítótár modell[1] egy végrehajtó egységből, memóriából, és egy gyorsítótárból áll. A végrehajtó egység a memóriát csak a gyorsítótáron keresztül éri el.

A végrehajtó egység a memóriát gépi szavanként éri el, ez egy kicsi konstans, például 8 bájt. Egy (Z, L) gyorsítótár L hosszú gyorsítótársorokból áll, és Z/L sort tartalmaz. Egy sor L gépi szót tárol, ezek a memóriában folytonosan helyezkednek el. Egy sor címe a memóriába csak a sorhossz többszöröse lehet. A gyorsítótár a memóriát gyorsítótársoronként tárolja. Egy sor a gyorsítótárban a memória bármelyik szakaszát tárolhatja.

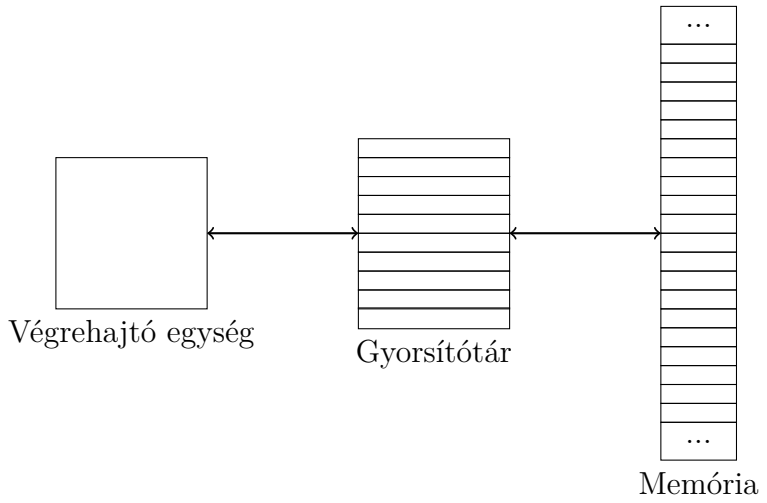

2.1. ábra. Az ideális gyorsítótár modell

Amikor a végrehajtó egység el akar érni egy adott szót a memóriában, a gyorsítótárhoz fordul. Ha a tárban van olyan sor, ami tartalmazza a kért gépi szót, akkor a gyorsítótár a kérést azonnal kiszolgálja. Ezt gyorsítótár-találatnak nevezzük. Ha a tár egyik sora se tartalmazza a kért szót, akkor a szóhoz tartozó sort a tár be kell olvassa a memóriából, majd ezután tudja teljesíteni a kérést. Ezt gyorsítótár-hibának

nevezzük.

Ha a tárban nincs üres sor amikor egy új sort be kell olvasni, akkor először egy sort ki kell ürítsen. Ha az ürítésre kiválasztott sor módosult a hozzá tartozó memóriához képest, akkor azt először vissza kell írnia a memóriába. Miután a sort szinkronizálta a memóriával, az új sorral felülírja az ürített sort.

A gyorsítótár-csere stratégiája diktálja, hogy a tár hogyan választja ki a sort, amit ürít. Az ideális gyorsítótár modell ürítési stratégiája az optimális offline stratégia[2]. Az optimális stratégia azt a sort üríti, amit a jövőben legkésőbb ér el a program a teljes futása során. Ez a stratégia használja ki a legjobban az időbeli lokalitást.

A gyorsítótár modellben az időbonyolultság az algoritmus futása alatt végzett elemi műveletek száma, a memóriaelérésekkel együtt. A gyorsítótár-bonyolultság a futás alatti találati hibák száma.

Egy algoritmus gyorsítótár-tudatos, ha van olyan fordítási vagy futási idejű paramétere, ami a gyorsítótár méretétől függ. Ha nincs ilyen paramétere, akkor az algoritmus gyorsítótár-független.

2.1. Csere stratégiák

Több csere stratégia is ismert:

- MIN, minimális, OPT, optimális, vagy Bélády algoritmusa: Ezt az elemet cseréli, amelyiket a jövőben legkésőbb éri el az algoritmus. Ennek eldöntésére szükség van a teljes memóriaelérési sorozatra.

- LRU, least recently used, legrégebben használt: Azt a sort cseréli, amit a legrégebben ért el az algoritmus. Ennek eldöntésére elég a csere pillanatáig ismerni az elérési sorozatot. Az LRU heurisztikája az a feltételezés, hogy az időben közelebbi elért memóriát valószínűleg újra el kell érni.

- LFU, least frequently used, legritkábban használt: A gyorsítótár nyilván tartja, hogy egy sort hányszor ért el az algoritmus mióta a gyorsítótárba került. Azt az elemet cseréli, amelyik elérési száma a legkisebb.

- FIFO, first in, first out, első be, első ki: Azt a sort cseréli, amelyik legrégebben került a tárba. A stratégia előnye az egyszerű megvalósíthatóság.

- Random, véletlen: A cserét véletlenszerűen választja ki. Az előnye az egyszerű implementáció.

Ha S egy gyorsítótár-csere stratégia, akkor legyen S(k) egy olyan gyorsítótár, ami az S stratégiát használja, és k sort tartalmaz.

2.1.1. Online algoritmusok

A gyakorlatban megvalósítható gyorsítótár-csere stratégiák online algoritmusok. Az online algoritmusok a bemenetüket sorban, egyesével kell feldolgozzák, a teljes bementet nem látják egyszerre. Egy gyorsítótár-csere algoritmusnak minden memória-eléréskor úgy kell döntést hozzon a cseréről, hogy csak a múltbeli elérések sorozatát ismeri.

Egy offline algoritmus a teljes bemenethez hozzáfér a teljes futása során.

A stratégiák elemzését egy egyszerűbb modellben[5] végezzük. Ezek a szabályok az igény szerinti lapozást írják le. Legyen $A = [1, 2, ..., n]$ az elérhető elemek halmaza. Legyen X egy A feletti véges sorozat, az elérések sorozata. Legyen $B_t(k)$ az $S(k)$ gyorsítótár tartalma X t hosszú prefixének feldolgozása után. Minden k-ra:

- Legyen $B_0(k) = \emptyset$. Tehát a gyorsítótár üres az algoritmus futása előtt.
- Ha $t > 0$, és $X_t \in B_{t-1}(k)$, akkor legyen $B_t k = B_{t-1}(k)$. Azaz találat esetén a gyorsítótár nem változtatja meg, hogy mely elemeket tartalmazza.
- Ha $t > 0$, $X_t \notin B_{t-1}(k)$, és $|B_{t-1}(k)| < k$, akkor legyen $B_t k = B_{t-1}(k) \cup \{X_t\}$. Ha van szabad hely a gyorsítótárban, akkor találati hiba esetén csere nélkül hozza be a memóriaelemet a tárba.
- Ha $t > 0$, $X_t \notin B_{t-1}(k)$, és $|B_{t-1}(k)| = k$, akkor legyen $y_t \in B_{t-1}(k)$, és $B_t(k) = B_{t-1}(k) \setminus y_t \cup \{X_t\}$. Találati hiba esetén ha nincs üres sor a tárban, akkor egy elemet kicserél, hogy behozhassa az elérni kívántat. A cserélendő elem az y_t, ezt a csere stratégia választja ki.

Ebben a modellben a gyorsítótárban nem sorok vannak, hanem A elemei. Ezek a gyorsítótár modellben a memória azon tartományai, amik gyorsítótár sorok lehetnek. Valamint az elérésben nem különböztetjük meg az olvasást és az írást.

2.1.2. Verem stratégiák

Egy S gyorsítótár-csere stratégiát verem algoritmusnak[5] nevezünk, ha teljesíti a következő feltételt. Legyen X egy memória-elérési sorozat. S verem algoritmus, ha minden $t \in 1, 2, ..., |X|$, és minden $k \in \mathbb{N}$-re

$$B_t(k) \subset B_t(k+1)$$

Azaz ha minden időpontban egy nagyobb gyorsítótár tartalmazza az összes kisebb gyorsítótár elemeit.

A verem algoritmusnak egy ekvivalens definíciója, ha S X futtatása közben minden $t \in 1, 2, ..., |X|$ időpontra ad egy egyértelmű preferencialistát az $\{X_1, X_2, ..., X_t\}$-ben előforduló elemekre, a gyorsítótár méretétől függetlenül, és egy $S(k)$ gyorsítótár csere esetén $B_t(k)$ elemei közül a legkisebb precedenciájút cseréli. A precedencialista nem feltétlen kell megegyezzen minden időpontban.

Egy verem algoritmust használva a gyorsítótár méretét növelve a találtai hibák száma nem nő. Nézzünk t időpontban egy gyorsítótár találatot $S(k)$-ban. Mivel $B_t(k) \subset B_t(k+1)$, ezért az elérés $S(k+1)$-ben is találat. Tehát minden k-nál nagyobb gyorsítótárban is találat az elérés.

Az LRU verem algoritmus.

Az OPT verem algoritmus.

Az LFU verem algoritmus, feltéve, hogy az egyenlő frekvenciájú elemekre minden időpontban létezik egy egyértelmű precedencia.

A FIFO nem verem algoritmus.

A véletlen startégi nem feltétlen verem algoritmus. Ha egyenletesen véletlenül választjuk ki egy $S(k)$ gyorsítótár elemét cserére, akkor pozitív a valószínűsége annak, hogy az $S(k+1)$ tár egy másik elemet választ. Ha a t időpontban a tár méretétől függetlenül egyenletes véletlenül kiválasztjuk $X_1, X_2, ..., X_t$ egyedi elemeinek egy permutációját, és ezt precedencialistaként használjuk a cserélt elem kiválasztására, akkor a véletlen stratégia verem algoritmus. Ez az RR stratégia. Egy adott $RR(k)$ gyorsítótárban egy elem ürítésének esélye $1/k$, tehát egyenletes eloszlású.

2.1.3. OPT

Az optimális stratégiánál jobb eredményt lehet elérni, ha nem követeljük meg, hogy egy elérést csak a gyorsítótárból lehet kiszolgálni. Nézzük a $X = (1, 2, 3, 1, 2)$ elérési sorozatot, a $t = 3$ időpontot, és egy kételemű gyorsítótárat. A gyorsítótár ekkor tele van, és $B_2(2) = \{1, 2\}$.

Nézzük az $OPT(2)$ stratégiát. A 3 tárba hozatalához egy elemet ki kell cserélnie. Cserére a 2-t választja, mert ez az elem lesz legkésőbb újra elérve. Így $B_3(2) = \{1, 3\}$. $t = 4$-ben az elérés találat, de $t = 5$-ben 2 már nincs a tárban, és találati hibát okoz. Tehát X kiszolgálásához 4 memóriaműveletre volt szükség, a $t \in \{1, 2, 3, 5\}$ időpontokban.

Nézzünk egy olyan optimális stratégiát, ahol csere nélkül, közvetlenül a memóriából is ki lehet szolgálni egy elérést. Ez a stratégia $t = 3$-ban a 3 elérést a memóriából közvetlenül szolgálja ki, és $B_3(2) = B_2(2) = \{1, 2\}$. Ekkor X kiszolgálásához elég 3 memóriaművelet, a $t \in \{1, 2, 3\}$ időpontokban.

2.1.4. LRU

Egy adott problémára a versenyképességi analízisben egy A online algoritmust hasonlítunk össze az O optimális offline algoritmussal. Legyen X egy inputsorozat, $A(X)$ az A műveletigénye X-en, és $O(X)$ az O műveletigénye X-en. Ekkor A k-versenyképes[6], ha létezik egy C konstans, hogy minden X inputsorozatra

$$A(X) \leq kO(X) + C$$

Ha $C = 0$, akkor A szigorúan k-versenyképes. A legkisebb ilyen k az A versenyképességi aránya.

Slater és Tarjan[7] megmutatta, hogy az LRU(k) az OPT(k^*)-hoz képest $k/(k - k^* + 1)$ versenyképes. Ha $k = k^*$, akkor az LRU k-versenyképes az OPT-hoz képest. Ha $k = 2k^*$, akkor az LRU(k) az OPT(k*)-hoz képest

$$k/(k - k^* + 1) = 2k^*/(2k^* - k^* + 1) = 2k^*/(k^* + 1) < 2$$

versenyképes[1].

Legyen A egy adott algoritmus. Legyen $LRU(n, Z, L)$ a gyorsítótár komplexitása A-nak egy n méretű bemeneten és egy LRU(Z, L) gyorsítótáron. Legyen $OPT(n, Z, L)$ a gyorsítótár komplexitása A-nak egy n méretű bemeneten és egy OPT(Z, L) gyorsítótáron. Ekkor az $LRU(n, Z, L)$ gyorsítótár komplexitás reguláris[1], ha

$$LRU(n, Z, L) = O(LRU(n, 2Z, L))$$

Tegyük fel, hogy A egy reguláris gyorsítótár komplexitású algoritmus. Ekkor

$$OPT(n, Z, L) \leq LRU(n, Z, L) = O(LRU(n, 2Z, L)) = O(OPT(n, Z, L)$$

az optimalitást, a regularitást, és a 2-versenyképességet felhasználva. Tehát

$$LRU(n, L, Z) = \Theta(OPT(n, L, Z)$$

2.1.5. FIFO

Bélády[3] megmutatta, hogy FIFO stratégiára létezik olyan k és K, $k < K$, és egy elérési sorozat, hogy ezen az elérési sorozaton a FIFO(K) több találati hibát eredményez, mint a FIFO(k). Fornai és Iványi megmutatta[4], hogy a hiba arányának nincs felső korlátja.

2.2. Asszociativitás

Az ideális gyorsítótár modellben a memória egy sorát a gyorsítótár bármelyik sorába be lehet hozni. Ezt hívják teljesen asszociatív gyorsítótárnak[8].

A gyakorlatban egy teljesen asszociatív gyorsítótár csak kevés sorra valósítható meg hatékonyan, mert minden elérésnél a gyorsítótárnak meg kell keresnie a sorok között, hogy tárolja-e az elérni kívánt sort.

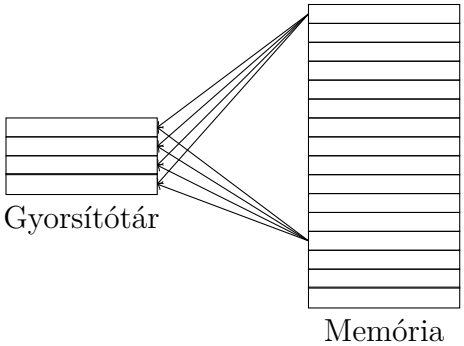

2.2. ábra. Teljesen asszociatív gyorsítótár

Közvetlen leképezésű gyorsítótárban[8] a memória egy sora a tárban csak egyetlen sorba hozható be. Ez a csere stratégiát is meghatározza, a beolvasni kívánt sor címe meghatározza a cserélt sort. Általában egy sor címét a gyorsítótárban a sor címének alsó bitjei határozzák meg, így a gyorsítótárba lehet hozni a memória egy egybefüggő szakaszát.

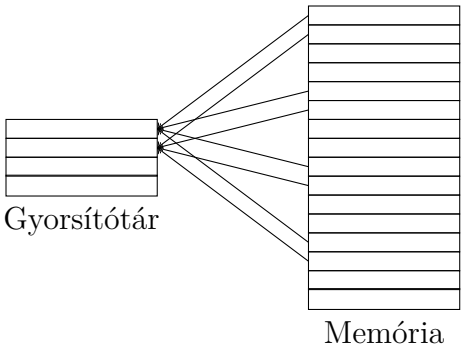

2.3. ábra. Közvetlen leképezésű gyorsítótár

Csoport-asszociatív gyorsítótárban[8] a memória egy sora a gyorsítótár több sorába is behozható, de nem az összesbe. A gyorsítótár több, egymástól független teljesen asszociatív gyorsítótárból áll. A memóriasor címe meghatározza, hogy a sor melyik asszociatív tárba kerül, és az asszociatív táron belül a csere stratégia alapján kerül elhelyezésre. Ha egy memóriasor A különböző gyorsítótár sorba kerülhet, akkor azt A-utas gyorsítótárnak nevezzük.

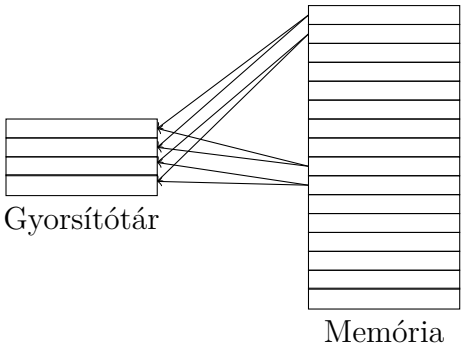

2.4. ábra. Csoport-asszociatív gyorsítótár

Tegyük fel, hogy a gyorsítótár paraméterei kettő-hatványok. A cache $Z = 2^z$ bájt, egy sor $L = 2^l$ bájt, és a cache $A = 2^a$ asszociatív, azaz egy memóriasor A gyorsítótár sorba kerülhet. Ekkor egy memóriabájt címének bitjeit egy lehetséges felosztása:

- Az l darab legkisebb helyi-értékű bit a bájt címe az őt befoglaló sorban.
- A következő $z-a$ helyi-értékű bit határozza meg, hogy a memóriasor a $C/(AL)$ darab teljesen asszociatív gyorsítótár közül melyikhez tartozik.
- A cím maradék bitjei meghatározzák, hogy egy teljesen asszociatív gyorsítótárhoz hány különböző sor tartozik.
- Ha $A = C/L$, akkor a gyorsítótár teljesen asszociatív.
- Ha $A = 1$, akkor a gyorsítótár közvetlen leképezésű.
- Ha $1 < A < C/L$, akkor a gyorsítótár A-utas.

2.3. Írási stratégia

A gyorsítótáraknak az írási műveleteket is kezelniük kell. Erre több különböző megoldás ismert[8].

Egy ha az írás olyan sort érint, amit a gyorsítótár tartalmaz, akkor az írási találat. Ilyenkor két megoldás közül lehet választani.

- A visszaírási (write back) stratégia az írást csak a gyorsítótárban végzi el, és az érintett sort megjelöli módosítottnak. Egy módosított sort a csere előtt a memóriába ki kell írni. Ezzel a megoldással memóriaműveletet lehet spórolni, ha ugyanarra a memóriasorra rövid időn belül több írás is történik. Ez a lehetséges hatékonyságnövelés növeli a megvalósítás áramköri komplexitását.

- A átmenő (write through) stratégia az írást a gyorsítótárban és a memóriában is elvégzi. A stratégia megvalósítása egyszerűbb, de minden írási művelet memóriaművelettel jár.

Ha az írási találati hibát is kétféleképpen kezelheti a gyorsítótár.

- Foglalással (write allocate) a gyorsítótár sorcserével a tárban is elhelyezi az írt sort. Ha az írás nem fedi le az egész memóriasort, akkor a gyorsítótár először az egész sort ki kell olvassa a memóriából, az olvasási találati hibához hasonló módon.

- Foglalás nélkül (no write allocate) a gyorsítótár az írást közvetlenül a memóriában végzi el, a saját tárát megkerülve. Ha a gyorsítótár ki kell tudjon szolgáljon olyan írásokat, amik nem a teljes memóriasort módosítják, akkor a memóriának támogatnia kell a memóriasornál finomabb elérési műveleteket.

Ezeknek a lehetőségeknek minden kombinációja megvalósítható, különböző bonyolultsággal.

- A módosított gyorsítótár sorok megnövelik a gyorsítótár állapotainak számát, és a műveletek állapotgépeinek állapotait is.

- A közvetlen memóriaírás a gyorsítótár megkerülésével szükségessé teszi, hogy a memóriát ténylegesen olyan finomsággal lehessen címezni, amilyen finoman a végrehajtó egység logikailag tudja címezni.

- Ha vannak párhuzamos gyorsítótárak, akkor ezek a megoldások a gyorsítótár koherenciára adott megoldást is befolyásolják. Párhuzamos gyorsítótárak előfordulhatnak egy végrehajtó egységgel is, például külön adat és utasítás gyorsítótár, és több végrehajtó egységgel rendelkező rendszerben is.

3. fejezet

Gyorsítótár független algoritmusok

3.1. Lista

Legyen A egy n elemű, N bájt hosszú tömb. A tömb elemei a memóriában folytonosan legyenek elrendezve. A feladat a tömb minden elemét sorban egyszer elérni. Ez az elérés lehet olvasás vagy írás is.

Tegyük fel, hogy a gyorsítótár mérete (Z, L), és létezik legalább egy gyorsítótársor, $Z \geq L$.

Ekkor a tömb minden elemeinek elérésének gyorsítótár bonyolultsága $O(1 + N/L)$. Az tömb eléréséhez legfeljebb 2 olyan memóriasort kell elérni, ahol a tömb nem fedi le az egész sort, a tömb elején és a tömb végén. A tömb többi eleme legfeljebb N/L memóriasort fed le teljesen.

3.1.1. Másolás

Legyen A egy n elemű, N bájt hosszú tömb. A tömb elemei a memóriában folytonosan legyenek elrendezve. A feladat a tömb minden elemét egy új memóriacímre másolni. A másolás történhet a tömbben előre és hátrafele is, attól függően, hogy a tömb régi és új helye hogyan fed át.

Tegyük fel, hogy a (Z, L) méretű gyorsítótárban legalább 2 gyorsítótársor van.

Ekkor az egyik gyorsítótársort az írásra használva, és a másik sort az olvasásra használva a másolás elvégezhető $2O(1 + N/Z) = O(1 + N/Z)$ memóriaművelettel.

3.1.2. Partíció

Legyen A egy n elemű, N bájt hosszú tömb. A tömb elemei a memóriában folytonosan legyenek elrendezve. Legyen T eldönthető tulajdonság, ami értelmezett a tömb minden elemére.

Rendezzük át helyben a tömböt úgy, hogy az összes olyan elem, amire a T tulajdonság hamis, a tömb elejére kerül, és azok az elemek, amikre a T tulajdonság igaz, a tömb végére kerülnek. A felosztás eredménye legyen a hamis tulajdonságú elemek száma.

A feladat a gyorsrendezés egy részfeladata, ahol a rendezendő tömb elemeit egy tengelyelem szerint két részre osztja, a tengelynél nem-nagyobbakra, és a tengelynél nagyobbakra. [9]

Algoritmus 3.1 Az $A[0 : n-1]$ tömb felosztása a T tulajdonság szerint

Require: A: a felosztandó tömb
Require: n: a tömb hossza
Require: T: egy eldönthető tulajdonság
Ensure: m: a hamis tulajdonságú elemek száma
Ensure: $A[0 : m-1]$ minden eleme hamis tulajdonságú T szerint
Ensure: $A[m : n-1]$ minden eleme igaz tulajdonságú T szerint
Ensure: az A kimenet az A bemenet permutációja

```
function FELOSZTÁS(A, n, T) → m
    l ← 0
    r ← 0
    while true do
        while (l + r < n) ∧ (¬T(A[l])) do
            l ← l + 1
        end while
        while (l + r < n) ∧ T(A[l]) do
            r ← r + 1
        end while
        if l + r ≥ n then
            return l
        end if
        t ← A[l]
        A[l] ← A[r]
        A[r] ← t
        l ← l + 1
        r ← r + 1
    end while
end function
```

Tegyük fel, hogy a gyorsítótár mérete (Z, L), és Z/L legalább akkor, hogy 3 tömbelemet a gyorsítótárban lehessen tartani, a memória bárhol elhelyezkedve. Mindig tároljuk a gyorsítótárban

- az l által vizsgált elemet,
- az r által vizsgált elemet,
- a cserénél használt ideiglenes t elemet.

Ekkor a felosztást legfeljebb $O(1 + N/L)$ memóriaművelettel el lehet végezni.

- Növekvő indexekkel legfeljebb a tömb összes memóriasorait egyszer járjuk be. Ez $O(1 + N/L)$ memóriaművelet.
- Csökkenő indexekkel legfeljebb a tömb összes memóriasorait egyszer járjuk be. Ez $O(1 + N/L)$ memóriaművelet.
- Az ideiglenes változóhoz tartozó memóriasorokat legfeljebb egyszer kell a gyorsítótárba hozni. Ez $O(1)$ memóriaművelet.

3.1.3. Leszámláló rendezés

A leszámláló rendezés egy lineáris műveletigényű, nem összehasonlításon alapuló rendezés.[9]

Legyen A egy n elemű, N bájt hosszú tömb. Legyen K egy kiszámítható függvény, ami a tömb minden elemét a $\{0, 1, ..., k - 1\}$ halmazba képzi. k legalább 2. Tipikusan k lényegesen kisebb, mint n. K az elemek kulcsát adja meg, ami szerint a tömböt rendezni szeretnénk.

A feladat a tömböt úgy átrendezni helyben, hogy sorban először az összes 0 kulcsú elem legyen, majd ezeket sorban kövesse az összes 1 kulcsú elem, és így tovább, végül a tömb végén a $k - 1$ kulcsú elemek helyezkedjenek el. A kimenetben adjuk meg minden lehetséges kulcsra azt is, hogy a tömbben hol helyezkednek el az adott kulcsú elemek.

A megoldás a tömb kétszeri bejárásával megadható.

- Inicializáljunk a $C[0 : k - 1]$ tömböt nullákkal, majd a tömb egyszeri bejárásával számoljuk meg a kulcsok frekvenciáját. Ez a C tömb a kimenet része is.
- Az $S[0 : k - 1]$ tömbben számítsuk ki a kulcsokhoz tartozó kezdőelemek indexeit. $S[0] = 0$, és $\forall i \in \{1, 2, ...k - 1\} : S[i] = S[i - 1] + C[i - 1]$. Ez az C és S egyszeri bejárásával kiszámítható. S a kimenet része.
- Másoljuk le S-t T-be. A következő dupla-ciklusban a T invariánsa a következő. Minden $k' \in \{0, 1, ..., k - 1\} : \forall i \in [S[k'], T[k']) \rightarrow K[A[i]] = k'$, azaz $S[k']$ és $T[k']$ között minden elem a helyén van.

- Járjuk be sorra k'-vel a $\{0, 1, ..., k-1\}$ kulcsokat. Minden k' kulcsra biztosítsuk, hogy a k'-höz tartozó szakasz minden eleme a megfelelő helyen van. Amíg $T[k'] - S[k']$ nem egyenlő $C[k']$-vel, addig legyen $i = T[k']$, és $k^* = K(A[i])$. Ha $k^* = k'$, akkor az $A[i]$ elem a helyén van, növeljük meg eggyel $T[k']$-t. Különben cseréljük meg $A[i]$-t és $A[T[k^*]]$-ot és növeljük meg eggyel $T[k^*]$-ot.

A megoldásban az utolsó ciklus minden lépésben egy elemet a helyére tesz, a ciklus invariánsa szerint, és egy elemet legfeljebb kétszer vizsgál meg.

Tegyük fel, hogy a gyorsítótár mérete (Z, L). Tegyük fel, hogy k darab számláló K' bájttal leírható. Valamint tegyük fel, hogy Z/L legalább akkora, hogy $2k$ darab számlálót, k darab tömbelemet, és egy ideiglenes elemet a cseréhez mindig a gyorsítótárban lehet tartani, függetlenül a elhelyezésüktől a memóriában. Ekkor:

- C kiszámításához k számlálót kell a gyorsítótárban tartani, miközben a A-t sorban bejárjuk. Ez legfeljebb $O(1+K'/L+N/L)$ memória műveletet igényel.

- S kiszámításához k számlálót kell összesíteni. Ez legfeljebb $O(1 + K'/L)$ memória műveletet igényel.

- T előállítása S másolásával, legfeljebb $O(1 + K'/L)$ memória művelet.

- Minden kulcs bejárása nem rosszabb, mint a teljes tömb bejárása, hiszen kulcsok szerint is sorba járjuk be, legfeljebb kihagyásokkal. A résztömbök végeit legfeljebb $O(k)$ memóriaművelettel a gyorsítótárba lehet hozni, és a köztes elemek bejárása legfeljebb $O(N/L)$ memóriaműveletet igényel. Feltettük, hogy a kulcsokhoz tartozó számlálók végig a gyorsítótárban vannak.

Tehát összesen a memóriaműveletek száma legfeljebb $O(1 + k + K'/L + N/L)$.

3.2. Mátrix szorzás

Legyen A egy $m \times n$ dimenziós mátrix, B egy $n \times p$ dimenziós mátrix, és legyen a feladat a $C = AB$ mátrix szorzat kiszámítása.

C definíció szerint $\forall i \in \{1, 2, ..., m\} : \forall j \in \{1, 2, ..., p\} : C_{i,j} = \sum_{k=1}^{n} : A_{i,k}B_{k,j}$.

A definíció szerinti implementáció három egymásba ágyazott ciklus, a külső az eredmény sorait járja be, a középső az eredmény oszlopait, és a belső ciklus a vektorszorzatot számolja ki. Ez a megoldás $\Theta(n^3)$ összeadást, szorzást, és memóriaműveletet igényel.

Tegyük fel, hogy a mátrixokat sorfolytonosan tároljuk. Tegyük fel, hogy $m = n = p$, és a gyorsítótár mérete (Z, L). Legyen n olyan nagy, hogy a gyorsítótár egy sora a mátrixok legfeljebb egy teljes sorát tárolja. Valamint legyen n legalább kétszer akkora, mint a gyorsítótár sorainak száma, Z/L.

Nézzük a definíció szerinti megoldás futtatásának azokat a memóriaeléréseit, ami a B mátrix elemeit olvassák. Ez n^2 alkalommal beolvassa a B mátrix egy-egy teljes oszlopát. Minden oszlop-beolvasás n értéket olvas be, és a feltevések szerint ehhez legalább n memóriasort kell beolvasni. Az oszlop beolvasásának az elején a gyorsítótár legfeljebb $n/2$ memóriasort tartalmaz. Így a teljes oszlop beolvasása legalább $n/2$ memóriaműveletet igényel. Tehát a definíció szerinti megoldás elegendően nagy mátrixok esetén legalább $n^3/2$ memóriaműveletet vált ki. Tehát a megoldás $\Theta(n^3)$ memóriaművelet bonyolultságú.

A definíció szerinti megoldás oszlopfolytonosan elrendezett mátrixot esetén is $\Theta(n^3)$ gyorsítótár bonyolultságú, a fenti érveléshez hasonlóan az A mátrix elérését vizsgálva.

3.2.1. Gyorsítótár tudatos

A mátrix szorzást block mátrixokkal is elvégezhetjük. Például legyen A és B egy-egy $2n \times 2n$ dimenziós mátrix, és osszuk fel mindkettőt 4 $n \times n$ dimenziós blokkokra.

$$A = \begin{pmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{pmatrix}$$
$$B = \begin{pmatrix} B_{1,1} & B_{1,2} \\ B_{2,1} & B_{2,2} \end{pmatrix}$$
$$C = \begin{pmatrix} C_{1,1} & C_{1,2} \\ C_{2,1} & C_{2,2} \end{pmatrix}$$

Ekkor $\forall i \in \{1,2\} : \forall j \in \{1,2\} : C_{i,j} = \sum_{k=1}^{2} A_{i,k} B_{k,j}$.

Legyen s a program egy paramétere. A mátrixok méretei legyenek s többszörösei, szükség esetén nullákkal kiegészítve a mátrixokat, és legyen $m = n = p$. A mátrixok legyen sorfolytonosan tárolva.

Tegyük fel, hogy a gyorsítótár magas[1], $Z = \Omega(L^2)$,

Legyen (Z, L) a gyorsítótár mérete, és s-t válasszuk a lehető legnagyobbnak úgy, hogy három darab $s \times s$ dimenziós mátrix befér a gyorsítótárba. Egy $s \times s$ mátrix $\Theta(s+s^2/L)$ gyorsítótár sorban fér el. A magas gyorsítótár feltétel miatt $s = \Theta(\sqrt{Z})$.

A blokkonkénti szorzást végezzük el a következőképpen:

- Nullázzuk a C mátrixot. Ez legfeljebb $O(n + n^2/L)$ memóriaművelettel jár. n sor van, és egy sor bejárása legfeljebb $O(1 + n/L)$ memóriaművelet.
- Járjuk be 3 ciklussal a rész-szorzatok blokk mátrixait. $i, j, k = 1, 2, ..., n/s$.
- Adjuk hozzá C részblokkjához a bemeneti részblokkok szorzatát.
  $C_{i,j} \leftarrow C_{i,j} + A_{i,k} B_{k,j}$.

A három mátrix gyorsítótára hozatala legfeljebb Z/L memóriaműveletet igényel, az s megválasztása miatt.

Összesen, nagy n-ekre, $\Theta(n + n^2/L + (n/\sqrt{Z})^3(Z/L)) = \Theta(n + n^2/L + n^3/L\sqrt{Z})$

3.2.2. Kettő-hatvány négyzetes mátrixok

Tegyük fel, hogy a mátrixok kettő-hatvány négyzetes mátrixok, $m = n = p = 2^k$. Legyenek a mátrixok sorfolytonosan elrendezve a memóriában.

A megoldásban rekurzívan osszuk a mátrixokat 4 felé. Legyen a rekurzió neve $Szorzat(A, B, C, n)$.

- Nullázzuk a C mátrixot. Ez legfeljebb $O(n + n^2/L)$ memóriaművelettel jár.
- Hívjuk meg a rekurzív függvényt, $Szorzat(A, B, C, n)$.
- A rekurzió alapesete az $n = 1$.
  $C_{1,1} \leftarrow C_{1,1} + A_{1,1}B_{1,1}$.
- Az általános eset $n > 1$. Osszuk mindhárom mátrixot négy-négy négyzetes blokkra.

$$A = \begin{pmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{pmatrix}$$
$$B = \begin{pmatrix} B_{1,1} & B_{1,2} \\ B_{2,1} & B_{2,2} \end{pmatrix}$$
$$C = \begin{pmatrix} C_{1,1} & C_{1,2} \\ C_{2,1} & C_{2,2} \end{pmatrix}$$

  Hívjuk meg nyolcszor a rekurziót.

  - $Szorzat(A_{1,1}, B_{1,1}, C_{1,1}, n/2)$.
  - $Szorzat(A_{1,2}, B_{2,1}, C_{1,1}, n/2)$.
  - $Szorzat(A_{1,1}, B_{1,2}, C_{1,2}, n/2)$.
  - $Szorzat(A_{1,2}, B_{2,2}, C_{1,2}, n/2)$.
  - $Szorzat(A_{2,1}, B_{1,1}, C_{2,1}, n/2)$.
  - $Szorzat(A_{2,2}, B_{2,1}, C_{2,1}, n/2)$.
  - $Szorzat(A_{2,1}, B_{1,2}, C_{2,2}, n/2)$.
  - $Szorzat(A_{2,2}, B_{2,2}, C_{2,2}, n/2)$.

A rekurzió műveletbonyolultságát leírja a következő rekurzív összefüggés.

$$T(1) = \Theta(1)$$
$$T(1) = 8T(n/2) + \Theta(1)$$

A mester tétel[9] felhasználásával $T(n) = \Theta(n^3)$.

Tegyük fel, hogy a gyorsítótár mérete (Z, L). Tegyük fel, hogy a gyorsítótár magas. Legyen t a legnagyobb olyan szám, hogy három darab 2^t méretű négyzetes mátrix elfér a gyorsítótárban. Legyen $s = 2^t$. Egy $s \times s$ mátrix $\Theta(s + s^2/L)$ gyorsítótár sorban fér el. A magas gyorsítótár feltétel miatt $s = \Theta(\sqrt{Z})$. A rekurzív fában az s méretű négyzetes mátrixok gyorsítótárba hozatala $\Theta((2^{k-t})^3 Z/L) = \Theta(n^3 Z/\sqrt{Z}^3 L) = \Theta(n^3/\sqrt{Z}L)$ memóriaműveletet igényel.

Az eredmény mátrix nullázásával együtt a memóriaműveletek száma a gyorsítótárral $\Theta(n + n^2/L + n^3/\sqrt{Z}L)$. Ez megegyezik a gyorsítótár tudatos megoldás gyorsítótár bonyolultságával, explicit gyorsítótár paraméter használata nélkül.

3.2.3. Gyorsítótár független

Általános méretű mátrixokra hasonló gyorsítótár független megoldást lehet adni, mint a kettő-hatvány négyzetes mátrixokra.

Legyen A egy $m \times n$ dimenziós mátrix, és B egy $n \times p$ dimenziós mátrix. Legyenek A, B, és C sorfolytonosan tárolva a memóriában. Legyen a rekurzió neve $Szorzat(A, B, C, m, n, p)$.

- Nullázuk a C mátrixot.
- Hívjuk meg a $Szorzat(A, B, C, m, n, p)$ mátrixot.
- A rekurzió alapesete az $m = n = p = 1$.
  $C_{1,1} \leftarrow C_{1,1} + A_{1,1}B_{1,1}$.
- Ha $m \geq \max(n, p)$, akkor legyen $m' = \lfloor m/2 \rfloor$, és osszuk fel A-t, és C-t,

  $$A = \begin{pmatrix} A_1 \\ A_2 \end{pmatrix}$$
  $$C = \begin{pmatrix} C_1 \\ C_2 \end{pmatrix}$$

  úgy, hogy A_1 és C_1 m' sorból áll. Hívjuk meg rekurzívan a függvényt:

  - $Szorzat(A_1, B, C_1, m', n, p)$
  - $Szorzat(A_2, B, C_2, m - m', n, p)$

- Ha $p \geq \max(m, n)$, akkor legyen $p' = \lfloor p/2 \rfloor$, és osszuk fel B-t, és C-t,

$$B = \begin{pmatrix} B_1 & B_2 \end{pmatrix}$$
$$C = \begin{pmatrix} C_1 & C_2 \end{pmatrix}$$

  úgy, hogy B_1 és C_1 p' oszlopból áll. Hívjuk meg rekurzívan a függvényt:

  - $Szorzat(A, B_1, C_1, m, n, p')$
  - $Szorzat(A, B_2, C_2, m, n, p - p')$

- Ha $n \geq \max(m, p)$, akkor legyen $n' = \lfloor n/2 \rfloor$, és osszuk fel A-t, és B-t,

$$A = \begin{pmatrix} A_1 & A_2 \end{pmatrix}$$
$$B = \begin{pmatrix} B_1 \\ B_2 \end{pmatrix}$$

  úgy, hogy A_1 n' oszlopból és B_1 n' sorból áll. Hívjuk meg rekurzívan a függvényt:

  - $Szorzat(A_1, B_1, C, m, n', p)$
  - $Szorzat(A_2, B_2, C, m, n - n', p)$

A megoldás időbonyolultsága $\Theta(mnp)$.

Tegyük fel, hogy a gyorsítótár mérete (Z, L). Tegyük fel, hogy a gyorsítótár magas. Ekkor a megoldás gyorsítótár bonyolultsága[1] $\Theta(m + n + p + (mn + mp + np)/L + mnp/LZ)$.

3.2.4. Strassen algoritmus

A Strassen algoritmus[10] a kettő-hatvány négyzetmátrixok szorzásához hasonlóan a mátrixokat négy-négy részre osztja, de az eredményt mindössze hét rekurzióval

számolja ki.

$$
\begin{aligned}
A &= \begin{pmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{pmatrix} \\
B &= \begin{pmatrix} B_{1,1} & B_{1,2} \\ B_{2,1} & B_{2,2} \end{pmatrix} \\
C &= \begin{pmatrix} C_{1,1} & C_{1,2} \\ C_{2,1} & C_{2,2} \end{pmatrix} \\
M_1 &= (A_{1,1} + A_{2,2})(B_{1,1} + B_{2,2}) \\
M_2 &= (A_{2,1} + A_{2,2})B_{1,1} \\
M_3 &= A_{1,1}(B_{1,2} - B_{2,2}) \\
M_4 &= A_{2,2}(B_{2,1} - B_{1,1}) \\
M_5 &= (A_{1,1} + A_{1,2})B_{2,2} \\
M_6 &= (A_{2,1} - A_{1,1})(B_{1,1} + B_{1,2}) \\
M_7 &= (A_{1,2} - A_{2,2})(B_{2,1} + B_{2,2}) \\
C_{1,1} &= M_1 + M_4 - M_5 + M_7 \\
C_{1,2} &= M_3 + M_5 \\
C_{2,1} &= M_2 + M_4 \\
C_{2,2} &= M_1 - M_2 + M_3 + M_6
\end{aligned}
$$

A rekurzív szorzások az M mátrixok kiszámításához szükségesek.

A Strassen algoritmus időbonyolultsága[10] $\Theta(n^{\log_2 7})$.

Legyen a gyorsítótár mérete (Z, L). Ekkor a Strassen algoritmus gyorsítótár bonyolultsága[1] $\Theta(n + n^2/L + n^{\log_2 7}/L\sqrt{Z})$.

3.2.5. Z-sorrend

Legyen A egy kettő-hatvány méretű négyzetes mátrix, és osszuk fel egyenlő méretű blokkokra.

$$
A = \begin{pmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{pmatrix}
$$

A memóriában úgy helyezzük el az A mátrixot, hogy először $A_{1,1}$ összes értékét tároljuk el, majd $A_{1,2}$-t, $A_{2,1}$-et, végül $A_{2,2}$-t. A blokkokat rekurzívan osszuk fel, ha nagyobbak mint egy, és azokat is ilyen sorrendben tároljuk. Például egy 4×4

dimenziós mátrix elemeinek sorrendje a memóriában:

$$A = \begin{pmatrix} 1 & 2 & 5 & 6 \\ 3 & 4 & 7 & 8 \\ 9 & 10 & 13 & 14 \\ 11 & 12 & 15 & 16 \end{pmatrix}$$

Ebben az elrendezésben a magas gyorsítótár feltételezés helyett elég a gyengébb feltétel is, hogy a a gyorsítótár sorainak száma egy elegendően nagy konstans.[1] Ha egy $s \times s$ méretű részmátrix $O(1)$ gyorsítótár sorban tárolható, akkor elég ha a gyorsítótárnak $3O(1) = O(1)$ sora van, hogy egy $s \times s$ méretű részfeladatot a gyorsítótárba egyszer beolvasva megoldjunk.

3.3. Rendezés

Katasztrofális.

Oszd meg és uralkodj. 2 algoritmus is van. Az alsó korlát elérhető, de a papír nem az igazi erről. Tall cache assumption. A tall cache assumption lényegesen befolyásolja a műveletigényt.

3.4. FFT

Katasztrofális.

Oszd meg és uralkodj. Alsó korlát is van, amit elér, de túl erős feltevésekkel.

3.5. Diff.egyenlet közelítés

Katasztrofális.

Oszd meg és uralkodj. Több dimenzióban.

3.6. Statikus keresőfa

Katasztrofális.

Van Emde Boas fák. Dinamikus eset szuperbonyolult, asszem.

3.7. Edénysor szita

Az edénysor szität a szakdolgozatomban írtam le. Ez egy eratoszthenészi rekurzívan szegmentált szita.

Az eratoszthenészi sziták prímek többszöröseit jelölik meg egy adott intervallumon, és egy-egy prím többszöröseinek megjelöléseit a többi prímtől függetlenül végzik. A szita alkalmas prímek keresésére is, és az intervallum számainak prímfaktorizációjára is.

Egy szegmentált szita a teljes intervallumot kisebb intervallumokra osztja, ezek a szegmensek, és a szegmensekben külön-külön végzi el a megjelöléseket. A szegmensek átfedés nélkül lefedik a teljes intervallumot. A szegmens méretet úgy választják meg, hogy szitáláshoz használt prímek és egy szegmens a gyorsítótárban elférjen. Ha a szegmensek mérete a program bemeneti paramétere, akkor a szita gyorsítótár tudatos.

A rekurzív edényszita egy a^h hosszú intervallumot szitál, ahol a és h természetes számok, $a \geq 2$. Ha $h > 0$, akkor az intervallumot a darab ugyanolyan hosszú részre osztja, és ezeket rekurzívan szitálja. A prímek listáját előszűri, hogy egy szegmensbe csak olyan prímeket vizsgáljon, amiknek ténylegesen van többszöröse a szegmensben.

3.7.1. A rekurzív fa

Vegyük a $[u, u+a^h)$ intervallumot, u természetes szám. és egy p prímet, aminek van többszöröse az intervallumban. Tegyük fel, hogy $h > 0$. Ekkor az i. részintervallum $[u + ia^{h-1}, u + (i+1)a^{h-1})$, minden $i \in 0, ..., a-1$-re.

- Ha $p \geq a^h$, akkor p-nek pontosan egy részintervallumban van többszöröse.
- Ha $a^{h-1} < p < a^h$, akkor p-nek legalább egy részintervallumban van többszöröse, de nem feltétlen mindegyikben.
- Ha $p \leq a^{h-1}$, akkor p-nek minden részintervallumban van többszöröse.

Példának nézzük meg, hogy az 5 milyen utat jár be a rekurzív fában a $[0, 2^4)$ intervallum szitálásakor. Az ábrán a prím 0-t is bejárja, ami prímek keresésekor nem következik be.

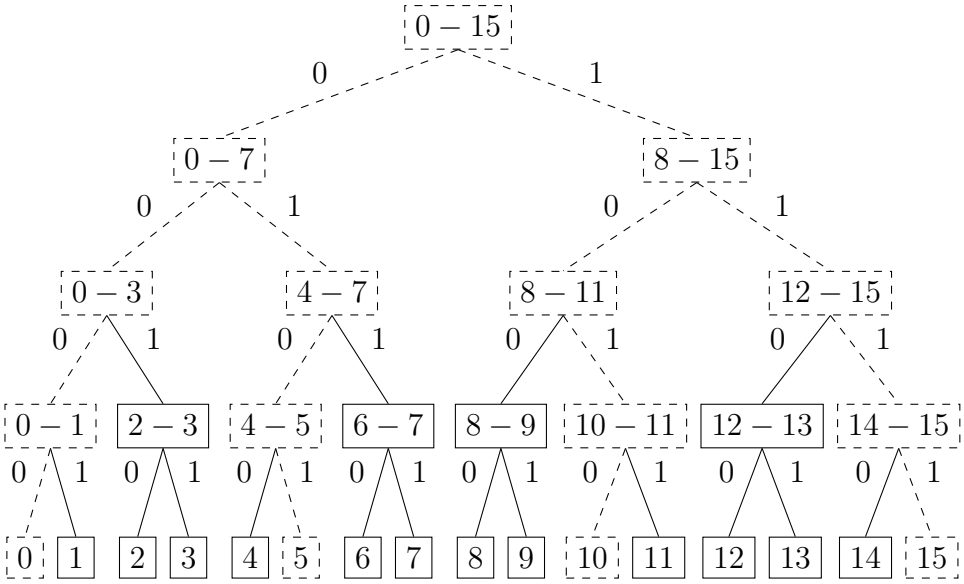

3.1. ábra. Az 5 többszörösei a $[0, 2^4)$ intervallumhoz tartozó rekurzív fában.

3.7.2. Rekurzív szita

Járjuk be a $[u, u + a^h)$ intervallumhoz tartozó rekurzív fát. A prímek listáján legyen minden olyan prím, ami kisebb u-nál. Minden levelet jelöljünk meg azokkal a prímekkel, amik a levélhez tartozó számot osztják. Ha egy levelet egyetlen prím sem oszt a listán, akkor az a szám prím, jelöljük meg magával, és adjuk a listához. A fa bejárásánál minden csúcsban előfeltétel, hogy a prímek listáján minden prím legalább egy levélhez tartozó számot oszt.

Egy belső csúcsban a gyerekeket sorban bejárjuk, és a prímek listáját előszűrjük, hogy megfeleljen a gyerekekre vonatkozó előfeltételnek. Azt az előszűrést kétféleképpen is elvégezhessük.

- A prímek listájában csak a prímeket tároljuk, és egy részintervallum végpontjainak ismeretében maradékos osztással eldöntjük, hogy van-e egy prímnek többszöröse. Ekkor a memóriaigényt számítási igényre cseréljük.

- A prímek listájában minden prím mellé eltároljuk, hogy melyik szám a következő többszöröse, és ezt hasonlítjuk össze az éppen következő részintervallummal. Ekkor a számítási igény memória igényre cseréljük.

A $[0, a^h)$ intervallum prím-faktorizációját a RekurzívSzita$(a, h, a^h, 0, \emptyset)$ hívással lehet elvégezni. A hívás után az intervallum egy száma prím, ha nincs megjelölve, és összetett, ha meg van jelölve, és az összes prímosztója megjelölte.

Prímek keresését a $[0, a^h)$ intervallumban a RekurzívSzita$(a, h, \left\lfloor \sqrt{a^h} \right\rfloor, 0, \emptyset)$ hívás lehet elvégezni. Az eredménylista tartalmazza a prímeket. Ebben az esetben a levelek megjelölése nem szükséges.

Algoritmus 3.2 Az $[u, u + a^h)$ intervallum szitálása

Require: a: a számrendszer alapja
Require: h: a fa magassága
Require: m: a keresett prímek felső korlátja
Require: u: a az intervallum kezdőpontja
Require: P: lista, azok a p prímszámok, hogy létezik p-nek többszöröse az $[u, u + a^h)$ intervallumban
Ensure: P: P kiegészítve az intervallumban talált prímekkel

```
function RekurzívSzita(a, h, m, u, P) → P
    if h = 0 then
        if P üres és u ≥ 2 then                ▷ u egy újonnan megtalált prím
            if u ≤ m then
                P ← P ∪ {u}
            end if
        end if
        jelöljük meg u-t P minden elemével
    else
        legyenek a részintervallumok I_i = [u + ia^{h−1}, u + (i + 1)a^{h−1}, i ∈ [0, a)
        Q legyen listák egy a elemű tömbje, és legyen minden lista üres
        for p ∈ P do
            Legyen i a legkisebb olyan szám, hogy p-nek van többszöröse I_i-ben
            Q[i] ← Q[i] ∪ {p}
            P ← P \ {p}
        end for
        for i = 0, ..., a − 1 do
            Q[i] ← RekurzívSzita(a, h − 1, m, u + ia^{h−1}, Q[i])
            for p ∈ Q[i] do
                if p-nek van többszöröse I_{i+1}, ..., I_{a−1}-ben then
                    legyen j a legkisebb olyan szám,
                    hogy p-nek van többszöröse I_{i+1}, ..., I_{a−1}-ben
                    Q[j] ← Q[j] ∪ {p}
                else
                    P ← P ∪ {p}
                end if
                Q[i] ← Q[i] \ {p}
            end for
        end for
    end if
    return P
end function
```

3.7.3. Műveletigény gyorsítótár nélkül

Tegyük fel, hogy a $[0, a^h)$ intervallumot szitáljuk. Legyen $n = a^h$, és m a minket érdeklő prímek felső korlátja. Legyen $p \leq m$ egy prím.

Nézzük a rekurzív fában az összes a^k hosszú részintervallumot, $k \leq h$.

- Ha $p > a^k$, akkor p-nek legfeljebb egy többszöröse van egy adott részintervallumban, és összesen $\lfloor n/p \rfloor$ többszöröse van, és ennyi a^k hosszú részintervallumot jár be.
- Ha $p \leq a^k$, akkor p-nek minden részintervallumban van többszöröse.

Mivel $p \leq a^k \Leftrightarrow log_a p \leq k$, így a rekurzív fában p legfeljebb a felső $h - \lfloor log_a p \rfloor + 1$ szinten jár be minden csúcsot. Az alsó $\lfloor log_a p \rfloor$ szinten szintenként $\lfloor n/p \rfloor$ csúcsot jár be. Legyen C_p azon csúcsok száma, amit p bejár.

$$C_p \leq \sum_{k=\lfloor \log_a p \rfloor + 1}^{h} a^{h-k} + \sum_{k=0}^{\lfloor log_a p \rfloor} \left\lfloor \frac{n}{p} \right\rfloor$$

Vizsgáljuk az összeg bal oldalát:

$$\begin{aligned}
\sum_{k=\lfloor \log_a p \rfloor + 1}^{h} a^{h-k} &= \sum_{k=0}^{h - \lfloor \log_a p \rfloor - 1} a^k \\
&= \frac{a^{h - \lfloor \log_a p \rfloor} - 1}{a - 1} \\
&< \frac{a^{h - \lfloor \log_a p \rfloor}}{a - 1} \\
&\leq \frac{2a^{h - \lfloor \log_a p \rfloor}}{a} \\
&= \frac{2a^h}{a^{\lfloor \log_a p \rfloor + 1}} \\
&= \frac{2n}{a^{\lfloor \log_a p \rfloor + 1}} \\
&< \frac{2n}{a^{\log_a p}} \\
&= \frac{2n}{p}
\end{aligned}$$

Vizsgáljuk az összeg jobb oldalát:

$$\begin{aligned}
\sum_{k=0}^{\lfloor \log_a p \rfloor} \left\lfloor \frac{n}{p} \right\rfloor &= (\lfloor \log_a p \rfloor + 1) \left\lfloor \frac{n}{p} \right\rfloor \\
&\leq (\log_a p + 1) \left\lfloor \frac{n}{p} \right\rfloor \\
&\leq (\log_a p + 1) \frac{n}{p} \\
&= \left(\frac{\ln p}{\ln a} + 1 \right) \frac{n}{p} \\
&= \frac{n \ln p}{p \ln a} + \frac{n}{p}
\end{aligned}$$

Az összegre vonatkozó két becslést egyesítve:

$$\begin{aligned}
C_p &= \frac{2n}{p} + \frac{n \ln p}{p \ln a} + \frac{n}{p} \\
&= \frac{3n}{p} + \frac{n \ln p}{p \ln a}
\end{aligned}$$

Az összes prím által meglátogatott csúcsok számának becsléséhez felhasználjuk Mertens két tételét.[11]

$$\begin{aligned}
\sum_{p \leq n} \frac{\ln p}{p} &= \ln n + O(1) \\
\sum_{p \leq n} \frac{1}{p} &= \ln \ln n + O(1)
\end{aligned}$$

Így az összes prím által meglátogatott csúcsok száma multiplicitással:

$$\begin{aligned}
C &= \sum_{p \leq m} C_p \\
&< \sum_{p \leq m} \left(\frac{3n}{p} + \frac{n \ln p}{p \ln a} \right) \\
&= \sum_{p \leq m} \frac{3n}{p} + \sum_{p \leq m} \frac{n \ln p}{p \ln a} \\
&= 3n \sum_{p \leq m} \frac{1}{p} + \frac{n}{\ln a} \sum_{p \leq m} \frac{\ln p}{p} \\
&= 3n(\ln \ln m + O(1)) + \frac{n}{\ln a}(\ln m + O(1)) \\
&= \frac{n \ln m}{\ln a} + 3n \ln \ln m + O(n)
\end{aligned}$$

Tegyük fel, hogy $m = n^q$, $0 < q \leq 1$ konstansra. Tipikusan $q \in \{\frac{1}{2}, 1\}$. Ekkor:

$$\begin{aligned}
C &< \frac{n \ln n^q}{\ln a} + 3n \ln \ln n^q + O(n) \\
&= \frac{nq \ln n}{\ln a} + 3n \ln (q \ln n) + O(n) \\
&= \frac{nq \ln n}{\ln a} + 3n \ln q + 3n \ln \ln n + O(n) \\
&= O\left(\frac{n \ln n}{\ln a} + n \ln \ln n\right)
\end{aligned}$$

A RekurzívSzita program egy adott belső csúcsában egy adott prímmel többször is foglalkozik.

- Kiosztja legalább egy részintervallumra. Intervallumonként $O(1)$ időben.
- Összegyűjti a visszatérési értékbe. Egyszer $O(1)$ időben.

Valamint vannak a-tól függő inicializálási lépések, $O(a)$ időben. Egy levél csúcsban minden prímmel $O(1)$ időt foglalkozik.

Az összesítéshez számoljuk el a a részintervallumra kiosztás költségét a részintervallum csúcsában. Így

- Egy levélben minden prímmel $O(1)$ időt foglalkozik.
- Egy belső csúcsban $O(a)$ időt tölt karbantartással, és prímenként $O(1)$ időt azzal, hogy rá osztották, vagy visszatér vele.

Tehát a teljes időigény

$$\begin{aligned}
T &= \sum_{k=1}^{h} a^{h-k} O(a) + CO(1) \\
&= \sum_{k=0}^{h-1} a^k O(a) + CO(1) \\
&= \frac{a^h - 1}{a - 1} O(a) + CO(1) \\
&= O(a^h) + CO(1) \\
&= O(n) + CO(1) \\
&= O(n) + O\left(\frac{n \ln n}{\ln a} + n \ln \ln n\right) \\
&= O\left(\frac{n \ln n}{\ln a} + n \ln \ln n\right)
\end{aligned}$$

3.7.4. A műveletigény alsó korlátja

Legyen a feladat a $[2, n)$ intervallumban minden szám prímfaktorizációja, $n = a^h$. Minden szám mellé írjuk fel az összes prímosztóját, egy a elemű ábécé felett. Minden ilyen feljegyzést az összes többitől függetlenül végezzünk el, azaz egy egy bejegyzés önmagában legyen értelmezhető.

Legyen $f_p = \left\lfloor \frac{n}{p} \right\rfloor$ a p prímet leíró szó frekvenciája a megoldásban. Legyen $F = \sum_{p \leq n} f_p$ az összesen leírt szavak száma. Mertens tétele[11] alapján alsó becsléseket adunk F-re.

$$\begin{aligned}
F &= \sum_{p \leq n} f_p \\
&= \sum_{p \leq n} \left\lfloor \frac{n}{p} \right\rfloor \\
&> \sum_{p \leq n} \left(\frac{n}{p} - 1 \right) \\
&= \sum_{p \leq n} \frac{n}{p} - \sum_{p \leq n} 1 \\
&= \sum_{p \leq n} \frac{n}{p} - \Pi(n) \\
&= \sum_{p \leq n} \frac{n}{p} + \Theta\left(\frac{n}{\ln n} \right) \\
&= n \sum_{p \leq n} \frac{1}{p} + \Theta\left(\frac{n}{\ln n} \right) \\
&= n \left(\ln \ln n + O(1) \right) + \Theta\left(\frac{n}{\ln n} \right) \\
&= n \ln \ln n + O(n)
\end{aligned}$$

Tehát a megoldás legalább $\Omega(n \ln \ln n)$ szó leírásával jár.

Adjunk F-re egy durvább alsó becslést. Válasszuk N_1-et olyan nagyra, hogy minden $n \geq N_1$-re:

$$F > n \ln \ln n + O(n) \geq n$$

Mertens tétele[11] alapján

$$\sum_{p \geq n} \frac{\ln p}{p} = \ln n + R(n), \text{ ahol } |R(n)| < 2$$

Ez alapján válasszuk meg úgy N_2-t, hogy minden $n \geq N_2$-re

$$\sum_{p \geq n} \frac{\ln p}{p} = \frac{\ln n}{2}$$

Tegyük fel, hogy $n \geq \max(N_1, N_2)$.

Legyen P_p a p prím relatív gyakorisága. P_p-re egy felső becslést adunk.

$$P_p = \frac{f_p}{F} = \frac{\left\lfloor \frac{n}{p} \right\rfloor}{F} \leq \frac{\frac{n}{p}}{F} < \frac{\frac{n}{p}}{n} = \frac{1}{p}$$

Tudjuk[13], hogy egy a elemű ábécé feletti optimális prefix kód esetén egy P relatív gyakoriságú szó hossza legalább $-\log_a P$. Legyen O egy optimális kód a feladat megoldására. Legyen l_p a p prímhez tartozó kódszó hossza O-ban. l_p-re alsó becslést adunk.

$$l_p \geq -\log_a P_p > -\log_a \frac{1}{p} = \log_a p$$

Legyen L az O kóddal leírt megoldás hossza. L-ra alsó becslést adunk.

$$
\begin{aligned}
L &\geq \sum_{p \leq n} f_p l_p \\
&> \sum_{p \leq n} f_p \log_a p \\
&= \frac{1}{\ln a} \sum_{p \leq n} f_p \ln p \\
&= \frac{1}{\ln a} \sum_{p \leq n} \left\lfloor \frac{n}{p} \right\rfloor \ln p \\
&> \frac{1}{\ln a} \sum_{p \leq n} \left(\frac{n}{p} - 1 \right) \ln p \\
&\geq \frac{1}{\ln a} \sum_{p \leq \frac{n}{2}} \left(\frac{n}{p} - 1 \right) \ln p \\
&\geq \frac{1}{\ln a} \sum_{p \leq \frac{n}{2}} \frac{n}{2p} \ln p \\
&= \frac{n}{2 \ln a} \sum_{p \leq \frac{n}{2}} \frac{\ln p}{p} \\
&\geq \frac{n \ln \frac{n}{2}}{4 \ln a} \\
&= \frac{n(\ln n - \ln 2)}{4 \ln a} \\
&= \frac{n \ln n}{4 \ln a} - \frac{n \ln 2}{4 \ln a} \\
&= \Omega \left(\frac{n \ln n}{\ln a} \right)
\end{aligned}
$$

A prímfaktorizálás fenti definíciója nem tökéletesen egyezik a rekurzív szitával. A faktorizálásban megköveteltük, hogy egy véges ábécé felett kell megadni a prímfaktorokat. A rekurzív szitában a számokat egy véges ábécé felett jártuk be, de a megjelöléshez használt prímek listájában feltettük, hogy a prímek n-től függetlenül $O(1)$ memóriával leírhatóak, és $O(1)$ műveletigénnyel manipulálhatóak.

3.7.5. Gyorsítótár független edény szita

Megadjuk a RekurzívSzita egy gyorsítótár független implementációját, $a = 2$-re.

A RekurzívSzita programban a lista implementációját nem adtuk meg. A lista legyen a memória egy összefüggő része. A memória legyen elég nagy, hogy a futás során az összes prímet tárolni tudja. A memóriát a futás során 3 részre osztjuk.

- A lista elején azok a prímek vannak, amiknek az adott csúcsban nincs többszörösük. Ez a szakasz tovább fel van osztva, a rekurzív hívások vermének minden

szintjéhez tartozik egy egybefüggő szakasz, ahol azok a prímek vannak, amiknek a híváshoz tartozó csúcsban van többszörösük, de a gyerek-hívás csúcsában nincs többszörösük. A lista legelején a legelső híváshoz tartozó prímek vannak.

- a lista közepén azok a prímek vannak, amiknek az adott csúcsban van többszörösük.
- a lista végén a nem használt memóriahelyek vannak.

A RekurzívSzita hívásnál bemenő paraméter a lista három pontja.

- A cím, ahonnan kezdve azok a prímek vannak a listában, amiknek ebben a csúcsban van többszöröse.
- A cím, ameddig a többszörössel rendelkező prímek tartanak, és a szabad helyek kezdődnek.
- Opcionálisan, a cím, amíg a szabad helyek tartanak. Ezt lehet használni annak detektálására, hogy elfogyott a hely a listában.

A kimenő paraméter a cím a listában, ameddig a csúcsban többszörössel rendelkező prímek tartanak. Ez lehet nagyobb a bemenő paraméternél, ha a szita új prímet talált.

Egy belső csúcsban a listát két particionálással elő lehet készíteni a rekurzív hívásra.

- Tegyük fel, L a lista, és a három cím a listában $i \leq j \leq k$. $A[i : j]$ tartalmazza a prímeket, amiknek van többszöröse a csúcsban. $A[j : k]$ a szabad helyek.
- Particionáljuk az $A[i : j]$ listát, úgy, hogy azokat a prímeket, amiknek nincs a bal gyerekben többszörösük, azokat a lista elejére helyezzük. A partíciókat elválasztó cím legyen l. Ekkor az $A[l : j]$ tartalmazza a bal gyerekben többszörössel rendelkező prímeket, és $A[j : k]$ a szabad elemek.
- Hívjuk meg rekurzívan a szitát a bal gyerekre, a három cím legyen l, j, és k.
- Az eredmény címmel írjuk felül j-t. Ezzel bekerül a hívás ezen szintjén is a listába minden új prím.
- Particionáljuk az $A[i : j]$ listát, úgy, hogy azokat a prímeket, amiknek nincs a jobb gyerekben többszörösük, azokat a lista elejére helyezzük. A partíciókat elválasztó cím legyen l. Ekkor az $A[l : j]$ tartalmazza a jobb gyerekben többszörössel rendelkező prímeket, és $A[j : k]$ a szabad elemek.
- Hívjuk meg rekurzívan a szitát a jobb gyerekre, a három cím legyen l, j, és k.

- Az eredmény címmel írjuk felül j-t. Ezzel bekerül a hívás ezen szintjén is a listába minden új prím.
- Adjuk vissza j-t.

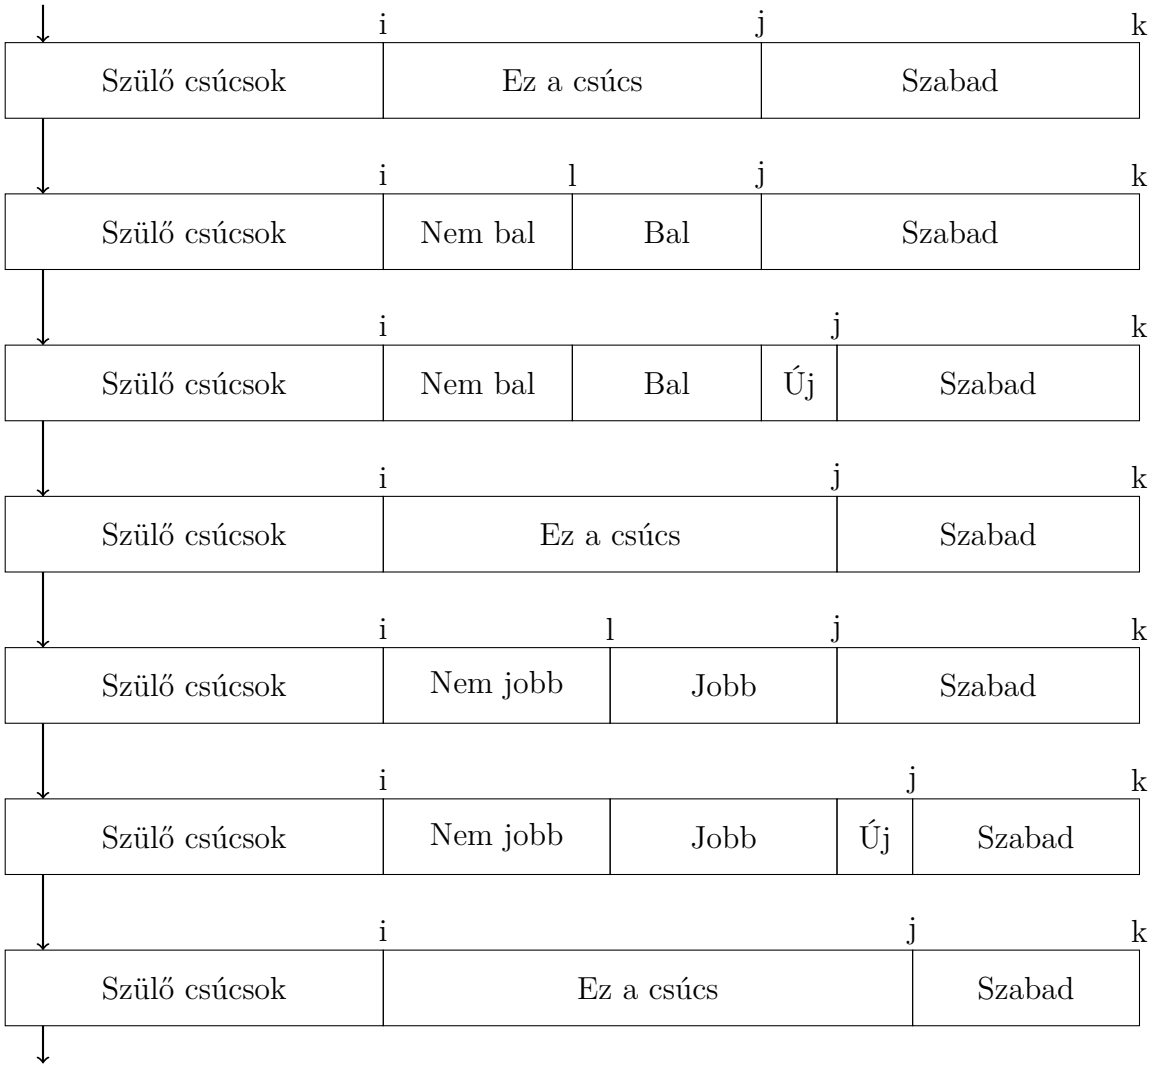

3.2. ábra. Gyorsítótár független particionálás

3.7.6. Műveletigény gyorsítótárral

Tegyük fel, hogy a gyorsítótár mérete (Z, L).

Tegyük fel, hogy egy csúcs bejárásakor a prímek kimeneti listája P memóriasorban fér el. Ekkor a particionálásokat legfeljebb $O(1 + P/L)$ memóriaművelettel el lehet végezni.

Tegyük fel, hogy egy k magas csúcs bejárásakor a prímek kimeneti listája P memóriasorban elfér. Tegyük fel, hogy a prímek teljes listája, és a rekurzív hívás

$k+1$-szer ismételt lokális változói is elférnek a gyorsítótárban. Ekkor az összes lokális változó helye, és a prímek listája legfeljebb $O(k+P/L)$ memóriaművelettel a gyorsítótárba hozható, és a csúcs és minden gyerekének bejárása nem vált ki további memóriaműveletet.

Tegyük fel, hogy a $[0,n)$ intervallumot szitáljuk, $n=a^h$, és egy a^k hosszú részintervallumhoz tartozó csúcsban járunk. Legyen p egy prím, $p<n$. Láttuk, hogy:

- Ha $p \leq a^k$, akkor p-nek minden a^k hosszú részintervallumban van többszöröse.
- Ha $p > a^k$, akkor p-nek nem minden a^k hosszú intervallumban van többszöröse. Összesen $\frac{n}{a^k} = a^{h-k}$ darab a^k hosszú részintervallum van. A p prímnek

$$\left\lfloor \frac{n}{p} \right\rfloor = \left\lfloor \frac{a^h}{p} \right\rfloor < \left\lfloor \frac{a^h}{a^k} \right\rfloor = \left\lfloor a^{h-k} \right\rfloor = a^{h-k}$$

  többszöröse van.

Ahhoz, hogy megbecsüljük a rekurzív szita viselkedését, feltesszük, hogy a prímek többszörösei teljesen egyenletesen oszlanak el a részintervallumok között, akár töredék súllyal is. Nézzük egy a^k hosszú részintervallumban a többszörösök súlyozott számát.

- Egy $p \leq a^k$ prímnek egy a súlya. A prímszám tétel[12] szerint ezek összesen

$$\Pi(a^k) = \Theta\left(\frac{a^k}{\ln a^k}\right) = \Theta\left(\frac{a^k}{k \ln a}\right)$$

- Egy $p > a^k$ prím súlya

$$\frac{\frac{n}{p}}{\frac{n}{a^k}} = \frac{a^k}{p}$$

Mertens tétele[11] szerint ekkor az összes ilyen prím összesített súlya

$$\begin{aligned}
\sum_{a^k<p\le a^h} \frac{a^k}{p} &= a^k \sum_{a^k<p\le a^h} \frac{1}{p} \\
&= a^k \left(\sum_{p\le a^h} \frac{1}{p} - \sum_{p\le a^k} \frac{1}{p} \right) \\
&= a^k \left(\ln\ln a^h - \ln\ln a^k + O(1) \right) \\
&= a^k \left(\ln\left(h \ln a\right) - \ln\left(k \ln a\right) + O(1) \right) \\
&= a^k \left(\ln h + \ln\ln a - \ln k - \ln\ln a + O(1) \right) \\
&= a^k \left(\ln h - \ln k + O(1) \right) \\
&= a^k \left(\ln \frac{h}{k} + O(1) \right) \\
&= a^k \ln \frac{h}{k} + O(a^k)
\end{aligned}$$

Összesen tehát egy a^k hosszú részintervallum súlyozott osztóinak a száma $O(a^k \ln \frac{h}{k})$

Nincs vége.

3.7.7. Cache-aware edényszita

3.7.8. Feltételek a gyorsítótár méretére

3.7.9. Tetszőleges n-ig, nem csak teljes fára

3.7.10. Az igazi program fix méretű számokkal

3.7.11. Az igazi program változó méretű számokkal

Valszeg nem lesz, mert semmi hasznosat nem tudok mondani.

4. fejezet

Szimulátor

4.1. Igazi cache

Asszociativitás. Több szint. Több mag osztozik. Léteznek egészen speciális cache-ek, TLB, decoded microcode, trace cache, ...

4.2. Megoldás

4.3. Választható cache-ek

- utasítás/adat/mindkettő
- MIN/OPT.
- LRU
- FIFO, LIFO, LFU, ..., kevésbé izgalmasak
- teljes/1-2-3...-n asszociativitás
- mindenféle méretben
- egymás után akár több is

4.4. Tesztek

5. fejezet

Mérési eredmények

6. fejezet

Irodalomjegyzék

[1] Frigo, M., Leiserson, C. E., Prokop, H., Ramachandran, S.: Cache-oblivious algorithms, ACM Transactions on Algorithms (TALG), 8(1) (2012)., 1-22.

[2] Belady, L. A.: A study of replacement algorithms for virtual storage computers. IBM Systems Journal 5, 2 (1966), 78–101.

[3] Belady, L. A.; Nelson, R. A.; Shedler, G. S.: An anomaly in space-time characteristics of certain programs running in a paging machine. Communications of the ACM, 12(6), (1969) 349–353.

[4] Fornai, P., Iványi, A.: FIFO anomaly is unbounded. (2010) arXiv preprint arXiv:1003.1336.

[5] Mattson, R.L., Gecsei, J., Slutz, D.R., Traiger, I.L.: Evaluation Techniques for Storage Hierarchies. IBM Syst. J., 9, (1970) 78-117.

[6] Aspnes, J. (1998). Competitive analysis of distributed algorithms. In: Fiat, A., Woeginger, G.J. (eds) Online Algorithms. Lecture Notes in Computer Science, vol 1442. Springer, Berlin, Heidelberg. https://doi.org/10.1007/BFb0029567

[7] Daniel D. Sleator and Robert E. Tarjan.: Amortized efficiency of list update and paging rules. Commun. ACM 28, 2 (Feb. 1985), 202–208.

[8] Hennessy, John L.; Patterson, David A. (2011). Computer Architecture: A Quantitative Approach. ISBN 978-0-12-383872-8.

[9] Cormen, Thomas A.; Leiserson, Charles E.; Rivest, Ronald L. (2001). Algoritmusok. ISBN 963-16-3029-3.

[10] Strassen , V. Gaussian elimination is not optimal. Numerische Mathematik 13 (1969), 354–356.

[11] Villarino, Mark. (2005). Mertens' Proof of Mertens' Theorem. Arxiv.

[12] Selberg, Atle. An Elementary Proof of the Prime-Number Theorem. Annals of Mathematics 50, no. 2 (1949): 305–13. https://doi.org/10.2307/1969455.

[13] Cover, T. M., Thomas, J. A. (2006). Elements of Information Theory (2nd ed.). Wiley-Interscience. ISBN: 978-0-471-24195-9. p.111.